

# Architectures parallèles

Xavier JUVIGNY

ONERA

30 Janvier 2018



# Plan du cours

## Prérequis et finalité du cours

## Introduction

- Motivations

## Architecture des ordinateurs parallèles

- Architecture SIMD

- Architecture MISD

- Architecture MIMD

## Mémoire partagée, mémoire distribuée et mémoire NUMA

- Mémoire partagée

  - Mémoire entrelacée

  - Mémoire cache

- Mémoire distribuée

- Architecture NUMA

# Prérequis et finalité du cours

## Prérequis

Une bonne expérience en programmation

Une bonne maîtrise du C++

## Finalité du cours

Connaître les concepts fondamentaux de la programmation parallèle ( hardware et software )

Maîtriser les outils de mesure de performance adaptés à la programmation parallèle

Être capable de concevoir un programme parallèle relativement complexe

Notion de programmation parallèle distribué

Notion de programmation parallèle partagé

Notion de programmation parallèle GPGPU

# Loi de Gordon Moore : la fin en 2017 ?

## Loi de Moore

Nombre de transistors double dans les processeurs tous les 24 mois.

## Loi de Moore et ses limitations

Loi auto-réalisatrice énoncé en 1965

Sert de feuille de route aux industriels

Hausse des fréquences & diminution de la taille des circuits :  
**problème de chaleur à dissiper**

Miniaturisation circuits : "mur quantique"  $\Rightarrow$  effet tunnel, ...


## Les alternatives

**Architecture multi-cœur** : palie le problème de chaleur mais programmation plus complexe.

Alternative au silicium ? Informatique quantique, processeurs neuromorphiques, processeurs 3D, transistors au graphène ?

# Motivation : Contrôle-commande

## Contrôle-commande sur une voiture



## Caractéristiques

Nombreux calculateurs dédiés à des fonctions diverses : freinage ABS, gestion moteur, éclairage, climatisation, etc.

Chaque calculateur doit optimiser un grand nombre de paramètres.

Moteur à combustion : pression air, température, mélange, allumage, etc.

Le tout en temps réel et chaque calculateur est inter-dépendant avec les autres.

# Motivation : Contrôle-commande (suite)

## Contrôle commande centrale nucléaire

- algorithmes contraints en temps réel

- Nombreux paramètres et calculs complexes

- Un seul cœur de calcul peut ne pas suffire à répondre à la contrainte temps réel


- Exploitation de l'architecture multi-cœur : exécution concurrente de tâches **indépendantes**

## Exemple logiciel distribué : **labview**

Le passage à la parallélisation de tâche a permis un traitement des données quinze fois plus rapide pour **labview** sur certaines plateformes.

# Motivation : Simulation de phénomènes physiques

## Problème aéro-acoustique



## But

calculer le bruit généré par de petites turbulences au niveau du bec de sécurité d'une aile d'avion

Petites turbulences  $\Rightarrow$  modèle précis & maillage très fin;

Sept milliards de sommets avec 5 inconnues par sommets

Mémoire nécessaire : 7 To

En séquentiel : 23 jours pour simuler  $\frac{1}{100}^e$  de secondes

# Motivation : Deep Learning

**Deep Learning** : apprentissage de modèles de données, Modélise un réseau neuronal.

internet ( reconnaissance d'images, traduction automatique, etc.)

médecine ( détection cellules cancéreuses, drogues, etc.),  
sécurité et la défense ( détection faciale, surveillance vidéo, etc.)

autonomie des machines (détection piéton, panneaux de signalisation )

Temps d'apprentissage :

Sur ordinateur séquentiel, plus d'un an d'apprentissage sur un ordinateur séquentiel.


Sur GPGPU, en parallèle, environ un mois pour le même apprentissage.

En Mars 2016, un logiciel de Go, Alphago a battu champion du monde. Apprentissage en trois semaines sur cinquante GPGPUs en parallèle.



# Motivation : Traitement de l'image

capteurs optiques pour navigation véhicules autonomes, super résolution sur images vidéos, etc.



GPGPU et parallélisme permettent un traitement d'un flux vidéo à trente images par secondes pour une résolution de  $1920 \times 1080$  pixels en temps réel.

# Taxonomie de Flynn

## Taxonomie de Flynn

Classification faite par Michael Flynn en 1967

**SISD** : Simple Instruction, Simple Data : architecture classique, programmation séquentielle classique


**SIMD** : Simple Instruction, Multiple Data : Une seule instruction exécutée à la fois mais appliquée sur plusieurs données simultanément : GPGPU, unités AVX et SSE.

**MISD** : Multiple Instruction, Simple Data : plusieurs instructions exécutées traitant simultanément une seule donnée : architectures pipelines associées aux registres vectoriels.

**MIMD** : Multiple Instruction, Multiple Data : plusieurs instructions qui traitent chacune des données différentes : ordinateurs multi-cœurs, calculateurs à mémoires distribuées.

De nos jours, un ordinateur possède plusieurs architectures parallèles.

# Architecture SIMD



Une unique instruction est exécutée simultanément par tous les unités de calcul sur ce type de machine, sur des données différentes.

# Architecture SIMD (suite)

Mise en œuvre des algorithmes délicat.

Instructions demandant sauts conditionnels très pénalisantes

On utilise une technique de masque pour les sauts conditionnels.

Pour traiter les branches conditionnelles :

Code d'origine

```
if ( a[i]>= 0 )  
    b[i] = c[i];  
else  
    b[i] = -d[i];
```

Code compilé pour la machine

```
msk[i] = (a[i]>=0); // = 1 si vrai, 0 sinon  
b[i] = msk[i] * c[i] - (1-msk[i]) * d[i];
```

# Les boucles conditionnelles en SIMD

Exemple : boucle sur suites de Mandelbrot

On calcule  $N$  suites  $z[i]$  avec  $z_{n+1}[i] = z_n^2[i] + c[i]$  avec  $c[i]$  complexe de module inférieur à deux.

Pour chaque suite, converge ? diverge ?

Diverge si  $|z_n[i]| \geq 2$ . On arrête de calculer la suite

Arrêt au bout de `nIterMax`

Code classique pour calculer la  $i^{\text{e}}$  suite de Mandelbrot

```
const long nIterMax = 65000;
z[i] = 0;
iter[i] = 0;
while ( (abs (z[i] ) < 2) && (iter[i] < nIterMax) )
{
    z[i] = z[i]*z[i]+c[i];
    iter[i] += 1;
}
```

## Les boucles conditionnelles en SIMD (suite)

Chaque unité de calcul doit continuer à itérer tant qu'une des suites n'a pas divergé;

Utilisation d'un système de masque pour que les suites divergentes stagnent;

On suppose être doté d'une instruction de réduction permettant de savoir si un des masques est encore vrai :

`reduce(msk, op::or)` effectue un ou logique sur toutes les valeurs de `msk`.

### Code transformé

```
const long nIterMax = 65000;
z[i] = 0;
iter[i] = 0;
msk[i] = true;
while reduce(msk, op::or)
{ // Tant qu'un des masques d'une UC est vrai
  z[i] = msk[i]*(z[i]*z[i]+c[i]) + (1-msk[i])*z[i];
  iter[i] += msk[i];
  msk[i] = (abs (z[i]) < 2) && (iter[i] < nIterMax);
}
```

# Bilan des sauts conditionnels sur SIMD

## En résumé


Les sauts conditionnels en SIMD sont traduits à l'aide d'une gestion de masque;

Cependant cela à un coût important puisqu'une unité de calcul SIMD doit toujours exécuter les deux branchements et non l'un ou l'autre;

La longueur des instructions dans chaque branche doit être limitée.

Il faut donc éviter au possible les sauts conditionnels !

# Architecture MISD




Plusieurs unités de calcul vont effectuer des opérations sur le même registre ( en principe, un registre vectoriel ), mais sur des parties différentes du registre.



# Architecture MISD (suite)


Ce type d'architecture recouvre actuellement les architectures pipelines associées à des registres vectoriels ( SSE – AVX ) sur les processeurs modernes :

```
for ( int i = 1; i <= 4; ++i )  
    r[i] = a[i] + b[i];
```



On remplit les registres vectoriels en même temps qu'on commence l'addition sur les parties des registres de  $a$  et  $b$  déjà remplies.

# Architecture MIMD



Cette architecture couvre une large gamme de machines, et est la plus commune actuellement :


- Les PCs actuels avec leurs multi-cœurs;

- Les calculateurs à mémoire distribuée ou NUMA;

- LES GPGPUs et leurs différentes unités de calculs.

# Performance relative de la mémoire vive

Composant de l'ordinateur limitant actuellement la vitesse de traitement des données :



# La mémoire partagée

Les unités de calcul partagent la même mémoire centrale au travers d'un bus mémoire.

La vitesse d'accès à la mémoire vive devenue critique pour les codes actuels.

Comment accélérer l'accès aux données ?

Principalement deux techniques complémentaires :

- La mémoire vive entrelacée;

- Une mémoire cache hiérarchique;

# La mémoire vive entrelacée

Nombre de voies : Nombre de mémoire qui sont entrelacées;

Largeur des voies : Nombre d'octets entre deux voies successives;

Exemple d'une mémoire entrelacée à quatre voies de largeur 3.




Un carré = un octet


Le bloc  $i, i \in [0, n - 1]$  contient toutes les cellules dont les adresses sont égales à  $w \times (n \times a + i) + k$  avec  $k \in [0, w - 1]$  et  $a \in \mathbb{N}$ .

# La mémoire vive entrelacée (suite)


## Accès à une mémoire non entrelacée



## Accès à une mémoire entrelacée à quatre voies



# Organisation de la mémoire cache sur une machine multi-processeurs



## Cohérence des données entre mémoires caches :

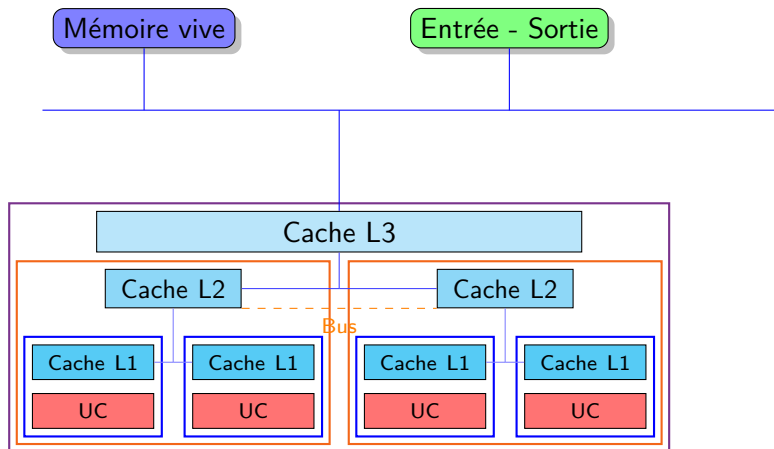
Une seule mémoire cache contient la donnée : donnée valide, aucune synchronisation nécessaire;

Donnée partagée avec d'autres caches : vérifier à chaque accès si modifiée par d'autres processeurs et alors la marquer comme invalide.

Valeur modifiée dans le cache et valeur en mémoire vive plus à jour : Mettre à jour la mémoire vive si d'autres processeurs veulent lire la valeur;

Valeur dans la mémoire cache invalide. La prochaine lecture de cette valeur déclenchera une lecture en mémoire vive.


# Organisation de la mémoire cache sur une machine multi-cœur



Même problème de cohérence des caches, mais également entre les niveaux de cache ! Complexité croissante avec le nombre de niveau hiérarchique de cache !



# Principe de la mémoire distribuée



Chaque unité de calcul possède sa propre mémoire vive :  
l'ensemble unité de calcul + mémoire vive est appelée **nœud de calcul**;

Les données sont échangées entre les nœuds de calcul au travers soit d'un bus spécialisé soit au travers un réseau intranet dédié;


Sur réseau, c'est à la charge du programmeur de transiter les données d'un nœud à l'autre;

Demande une programmation et des algorithmes spécifiques pour exploiter au mieux de type de machine;

Permet d'exploiter plusieurs centaines de milliers de nœuds de calcul;

Cependant limité par la consommation électrique !

# Architecture NUMA



Machine contenant des nœuds de calcul;

Chaque nœud contient plusieurs unités de calcul;

Les nœuds de calcul sont reliés par un crossbar;

Du point de vue programmeur, la mémoire est partagée;

Mais les temps d'accès aux données varient fortement selon qu'une unité de calcul accède à une donnée se trouvant sur son nœud de calcul ou sur un nœud de calcul distant.

# Architecture NUMA

On trouve des architectures NUMA dans les Xeons des processeurs INTEL. Chaque chipset est un nœud de calcul relié par un crossbar appelé **QPI** ( Quick Path Interconnect ) dans la terminologie d'INTEL;

Programme classique multi-thread fonctionne mais peu optimiser;

L'optimisation demande de fixer chaque thread à une unité de calcul : c'est **l'affinité**;

Le programmeur peut ensuite contrôler la répartition des données sur les nœuds de calcul à l'aide d'une politique choisie parmi les suivantes ( non exhaustive ) :

default	Allocation sur le nœud local où s'exécute le processus
First Touch Policy	L'allocation ne se fait pour une page mémoire que lors du premier accès à une donnée de cette page. L'allocation se fait alors pour cette page sur le nœud local où s'exécute le processus
Interleaving	L'allocation d'un tableau se fait en distribuant de façon cyclique les pages mémoires sur les différents nœuds de calcul